



MODELOS COMPUTACIONALES: CUARTO CURSO DEL GRADO DE ING. INFORMÁTICA EN COMPUTACION

Clasificación: Redes Bayesianas


César Hervás-Martínez
Grupo de Investigación AYRNA

**Departamento de Informática y Análisis
Numérico**
Universidad de Córdoba
Campus de Rabanales. Edificio Einstein.
Email: chervas@uco.es

2018-2019



Probabilidad condicionada. Espacio de probabilidad condicionado



La probabilidad condicionada es uno de los conceptos clave en Teoría de la Probabilidad.

Hay situaciones en las que se incorpora información suplementaria asociada a la ocurrencia de otro suceso, con lo que puede variar el espacio de resultados posibles y consecuentemente, sus probabilidades.

En este contexto aparece el concepto de probabilidad condicionada



Probabilidad condicionada. Espacio de probabilidad condicionado



Definición.- Sea (Ω, \mathcal{A}, P) un espacio probabilístico arbitrario y A un suceso ($A \in \mathcal{A}$) tal que $P(A) > 0$. Para cualquier otro suceso $B \in \mathcal{A}$, se define la probabilidad condicionada de B dado A o probabilidad de B condicionada a A como

$$P(B/A) = P(B \cap A) / P(A) .$$

Observemos que la condición $P(A) > 0$ es necesaria para que la definición tenga sentido. Por otra parte, la idea intuitiva de probabilidad condicionada hace lógica esta restricción ya que si $P(A)=0$, A es un suceso imposible y no tiene sentido condicionar a él.

Notemos que, sabiendo que $A \in \mathcal{A}$ ha ocurrido, tenemos una nueva evaluación de la probabilidad de cada suceso que pasa de ser $P(B)$ a $P(B/A)$, o sea, tenemos una nueva función de conjunto sobre (Ω, \mathcal{A}) , que, efectivamente, esta función es una medida de probabilidad sobre (Ω, \mathcal{A})



Introducción: Independencia de sucesos



INDEPENDENCIA ESTOCÁSTICA DE SUCESOS:

Sean A y B dos sucesos con probabilidades no nulas, luego existen $P(A)$ y $P(B)$ y no son cero, se dice que son independientes cuando se verifica que

$$P(A \cap B) = P(A)P(B),$$

siendo $P(A) > 0$ y $P(B) > 0$ y $A \cap B \neq \emptyset$

De esta forma dos sucesos A y B son estocásticamente independientes cuando la información sobre la ocurrencia de uno de ellos no modifica la probabilidad de que ocurra el otro. Esto es :

$$P(A \cap B) = P(A)P(B / A) = P(B)P(A / B)$$

pero si son independientes $P(B/A)=P(B)$

o equivalentemente $P(A/B)=P(A)$



Introducción



Hipótesis de independencia

Son necesarias para desarrollar una inferencia probabilística más practica

Método Naïve Bayes

Hace hipótesis de independencia que a menudo no son ciertas
También se le llama por esta razón Método Bayesiano Simple

Red Bayesiana

Modela explícitamente las relaciones de independencia de las variables asociadas a los datos

Utiliza estas relaciones de independencia para hacer inferencias probabilísticas

También se la conoce como: Red de Creencia, Red Bayes, Red Causal, etc



¿Porque Redes Bayesianas?

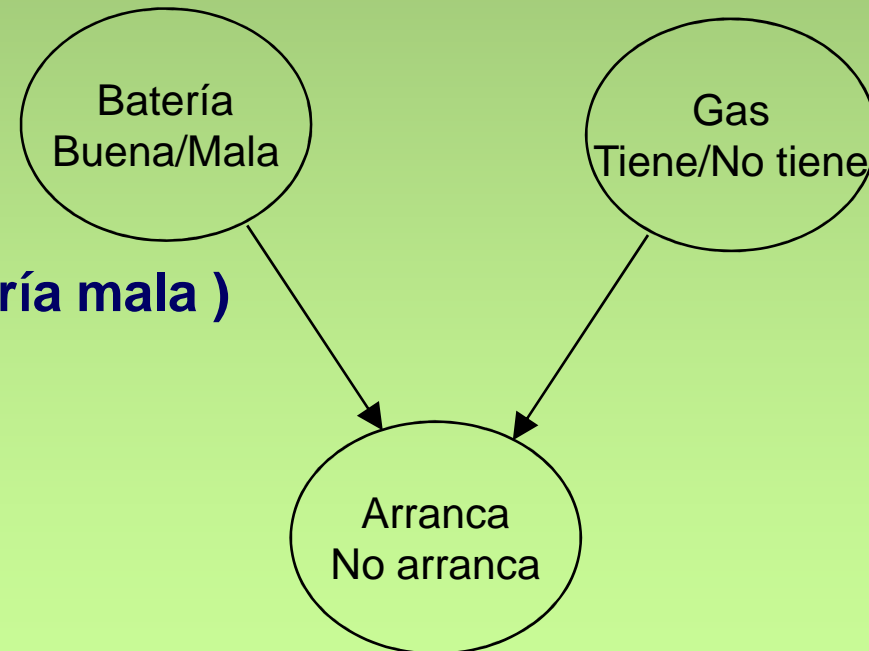


1) Lenguaje intuitivo

Puede utilizar conocimiento causal en la construcción de los modelos. Los expertos en el dominio de aplicación pueden construir de forma confortable la red.

2) Algoritmos de inferencia de propósito general

$P(\text{No arranca} \mid \text{Tiene gas, Batería mala})$



3) **Exacta:** Las especificaciones modulares permiten grandes eficiencias computacionales




Redes Bayesianas: Aplicaciones



- **Búsqueda inteligente en Google**
- **Recuperación de información**
- **Filtrado colaborativo y tecnología de recomendación**
- **Sistemas expertos para el diagnóstico médico**
- **Minería de datos**
- **Evaluación de riesgos y predicción de la calidad en los sistemas**
- **Predicción de riesgo en el tráfico aéreo**
- **Visión por Computador**
- **Colisión de aeronaves y drones**
- **Análisis de defectos de software**
- **Fiabilidad de Sistemas y disponibilidad**
- **Riesgo operacional en instituciones financieras**
- **Cartera de proyectos de riesgo**



Independencia de variables



Definición de variable aleatoria

Un conjunto de variable aleatorias son independientes cuando la distribución de probabilidad conjunta es el producto de las distribuciones de probabilidad marginales:

Ejemplo

v. a. X: Presión sanguínea de un paciente {alta, media, baja} v. a. Y: Paciente con estornudos {si, no}

$$P(X=x_i, Y=y_j) = P(X=x_i) \cdot P(Y=y_j) \text{ para todo } i, j$$

Como un ejemplo

$$P(X=\text{alta}, Y=\text{si}) = P(X=\text{alta}) \cdot P(Y=\text{si})$$

Se verifica una independencia condicional entre un conjunto de variables, si se verifica dicha independencia condicional entre todos los posibles sucesos de las variables.



Probabilidad Condicionada



A: 'Una persona tiene cáncer' $P(A) = 0,1$ ("a priori")

B: 'Una persona es fumador' $P(B) = 0,5$

¿Cual es la probabilidad $P(A | B)$? ("a posteriori")

$P(B | A) = 0,8$ (verosimilitud "*likelihood*")

Probabilidad a posteriori Probabilidad a priori Verosimilitud


$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B | A)}{P(B)}$$

Diagram showing arrows pointing from the text above to the formula: a vertical arrow from 'Probabilidad a posteriori' to $P(A | B)$, a vertical arrow from 'Probabilidad a priori' to $P(A)$, and a diagonal arrow from 'Verosimilitud' to $P(B | A)$.

$$P(A | B) = \frac{0,1 \times 0,8}{0,5} = 0,16$$



Introducción a las Redes Bayesianas



Las Redes Bayesianas son grafos acíclicos directos (DAGs).

Los nodos de las Redes Bayesianas representan a las variables aleatorias, las cuales “a priori” consideraremos que toman valores discretos.

Los enlaces de la red representan una influencia directa probabilística.

La estructura de la red representa la relación de dependencia/independencia probabilística entre las variables aleatorias representadas por los nodos



Independencia condicional de sucesos



Dos sucesos A y B son **condicionalmente independientes** si para cualquier suceso C con $P(C) > 0$

$$P(A \cap B / C) = P(A / C)P(B / C) \quad (1)$$

Si recordamos la definición de probabilidad condicional,

$$P(A / B) = \frac{P(A \cap B)}{P(B)}, \text{ si } P(B) \neq 0$$

Si condicionamos la anterior probabilidad sobre C, obtenemos

$$P(A / B \cap C) = \frac{P(A \cap B \cap C)}{P(B \cap C)} = \frac{P((A \cap B) / C)P(C)}{P(B / C)P(C)} = \frac{P((A \cap B) / C)}{P(B / C)},$$

si $P(C) \neq 0$ y si $P(B / C) \neq 0$

Si A y B son **condicionalmente independientes** dado C, tenemos

$$P(A / B \cap C) = \frac{P((A \cap B) / C)}{P(B / C)} = \frac{P(A / C)P(B / C)}{P(B / C)} = P(A / C)$$


Entonces si A y B son **condicionalmente independientes** dado C, tenemos que

$$P(A / B \cap C) = P(A / C) \quad (2)$$

De las ecuaciones (1) y (2) deducimos que son definiciones similares de independencia condicional



Independencia condicional de conjuntos



Def.- Independencia Condicional

Dados Y, Z, W tres conjuntos disjuntos de variables, se dice que Y es condicionalmente independiente de Z dado W , si se verifica que para algún y, z, w :

$$p(y | z, w) = p(y | w)$$

Estructura de una Red Bayesiana

Para cada variable X_i , la estructura S para X representa la afirmación de que X_i y $\{X_1, \dots, X_n\} / \mathbf{pa}_i^S$ son independientes, dado que \mathbf{pa}_i^S es el conjunto de padres de X_i en S)

Factorización de la Distribución de Probabilidad Conjunta

$$p(\mathbf{x}) = p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i | \mathbf{pa}_i^S)$$



Introducción a las Redes Bayesianas



Factorización de la distribución de probabilidad conjunta

Ejemplos $p(\mathbf{x}) = p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid \mathbf{pa}_i^S)$

$x_i \in B(p_i)$, esto es, si x_i se distribuye

según una distribución de Bernoulli de parámetro p_i

$$p(\mathbf{x}) = p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid \mathbf{pa}_i^S) = \prod_{i=1}^n (p_i)^{x_i} (1 - p_i)^{(1-x_i)},$$

donde $p_i = p(x_i \mid \mathbf{pa}_i^S)$


$x_i \in N(\mu_i, \sigma_i^2)$, esto es, si x_i se distribuye según una

distribución Normal de media μ_i y de varianza σ_i^2

$$p(\mathbf{x}) = p(x_1, \dots, x_n) = \prod_{i=1}^n (2\pi\sigma_i)^{-1/2} \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}\right)$$



Estructura y parámetros del modelo



Redes Bayesianas: Ventajas Representación


Basada en la teoría de la probabilidad, proporciona una semántica clara (basada en la independencia condicional entre tripletas de variables) y un sólido fundamento teórico

Representación del conocimiento: gráfico e intuitivo

Modularidad: reducción del número de parámetros para especificar la distribución conjunta de probabilidad



Estructura y parámetros del modelo



$$\mathbf{x}_1 = (x_1^1, x_1^2), \mathbf{x}_2 = (x_2^1, x_2^2), \mathbf{x}_3 = (x_3^1, x_3^2)$$

Parámetros del modelo y distribuciones de probabilidad locales

$$p(x_i^k \mid \mathbf{pa}_i^{j,S}, \theta_i) = \theta_{x_i^k \mid \mathbf{pa}_i^{j,S}} \equiv \theta_{ijk}$$

$$\boldsymbol{\theta}_1 = (\theta_{11}, \theta_{12}) \quad p(x_1^1 \mid \boldsymbol{\theta}_1), \quad p(x_1^2 \mid \boldsymbol{\theta}_1)$$

$$\boldsymbol{\theta}_2 = (\theta_{21}, \theta_{22}) \quad p(x_2^1 \mid \boldsymbol{\theta}_2), \quad p(x_2^2 \mid \boldsymbol{\theta}_2)$$

$$\boldsymbol{\theta}_3 = (\theta_{311}, \theta_{312}) \quad p(x_3^1 \mid x_1^1, x_2^1, \boldsymbol{\theta}_3), \quad p(x_3^2 \mid x_1^1, x_2^1, \boldsymbol{\theta}_3)$$

$$(\theta_{321}, \theta_{322}) \quad p(x_3^1 \mid x_1^1, x_2^2, \boldsymbol{\theta}_3), \quad p(x_3^2 \mid x_1^1, x_2^2, \boldsymbol{\theta}_3)$$

$$(\theta_{331}, \theta_{332}) \quad p(x_3^1 \mid x_1^2, x_2^1, \boldsymbol{\theta}_3), \quad p(x_3^2 \mid x_1^2, x_2^1, \boldsymbol{\theta}_3)$$

$$(\theta_{341}, \theta_{342}) \quad p(x_3^1 \mid x_1^2, x_2^2, \boldsymbol{\theta}_3), \quad p(x_3^2 \mid x_1^2, x_2^2, \boldsymbol{\theta}_3)$$

Factorización de la distribución de probabilidad conjunta

$$p(\mathbf{x} \mid \boldsymbol{\theta}_S) = p(\mathbf{x}_1 \mid \boldsymbol{\theta}_1) p(\mathbf{x}_2 \mid \boldsymbol{\theta}_2) p(\mathbf{x}_3 \mid \mathbf{x}_1, \mathbf{x}_2, \boldsymbol{\theta}_3)$$



Redes Bayesianas: Ventajas



Inferencia.- Razonamiento (propagación de la evidencia) mediante algoritmos exactos y aproximados

- Probabilidad de un suceso dada una evidencia
- Explicación más probable (inferencia abductiva o generación de hipótesis) como el suceso que mejor explica la evidencia actual. Es un tipo de razonamiento que a partir de la descripción de un hecho o fenómeno ofrece o llega a una hipótesis.

Aprendizaje a partir de los datos

Tres maneras principales de construir redes Bayesianas:

- **Manual** (mediante la ayuda de un experto en el dominio a ser modelado)
- **Induciendo a partir de una base de datos de casos (Aprendizaje a partir de datos)**
- **Aproximaciones mixtas**



Clasificadores Bayesianos



Estimador de máxima probabilidad, MPE, para C dado X

$$\begin{aligned} C^* &= \arg \max_c P(C = c \mid X_1 = x_1, \dots, X_n = x_n) = \\ &= \arg \max_c \frac{P((C = c) \cap (X_1 = x_1, \dots, X_n = x_n))}{P(X_1 = x_1, \dots, X_n = x_n)} = \\ &= \arg \max_c P(C = c)P(X_1 = x_1, \dots, X_n = x_n \mid C = c) \end{aligned}$$

Dependiendo de la factorización de:

$$P(X_1 = x_1, \dots, X_n = x_n \mid C = c)$$

Obtenemos diferentes clasificadores Bayesianos



Clasificadores Bayesianos



Dependiendo de la factorización de:

$$P(X_1 = x_1, \dots, X_n = x_n \mid C = c)$$

Obtenemos diferentes clasificadores Bayesianos

Modelos Jerárquicos de Clasificadores Bayesianos

- Naïve Bayes (Minsky, 1961)
- Seminaïve Bayes (Pazzani, 1997)
- Naïve Bayes aumentado a árbol (Friedman y col., 1997)
- Clasificador Bayesiano k-dependiente (Sahami, 1996)
- Red Bayesiana (Jensen, 2001)



Clasificadores Bayesianos



Clasificación Supervisada con Paradigmas Probabilistas

$$\begin{aligned} C^* &= \arg \max_c P(C = c \mid X_1 = x_1, \dots, X_n = x_n) = \\ &= \arg \max_c \frac{P((C = c) \cap (X_1 = x_1, \dots, X_n = x_n))}{P(X_1 = x_1, \dots, X_n = x_n)} = \\ &= \arg \max_c P(C = c)P(X_1 = x_1, \dots, X_n = x_n \mid C = c) \end{aligned}$$

$$\gamma : (x_1, \dots, x_n) \rightarrow \{1, 2, \dots, J\}$$

Matriz de costes: $C(r, s)$

Minimización del coste total de errores

$$\gamma(\mathbf{x}) = \arg \min_k \sum_{c=1}^J C(k, c) P(c \mid x_1, \dots, x_n)$$

Función de pérdida 0/1





$$\gamma(\mathbf{x}) = \arg \max_c P(c \mid x_1, \dots, x_n)$$



Clasificadores Bayesianos



Estructura de diferentes clasificadores Bayesianos
dependiendo de la factorización de
 $P(X_1 = x_1, \dots, X_n = x_n | C = c)$





Naïve Bayes



Formulación clásica de un problema de diagnóstico

- m diagnósticos posibles **no excluyentes**

	$x_1,$	\dots	x_n	$y_1,$	$\dots,$	y_m
$(x^{(1)}, y^{(1)})$	$x_1^{(1)}$	\dots	$x_n^{(1)}$	$y_1^{(1)}$	\dots	$y_m^{(1)}$
$(x^{(2)}, y^{(2)})$	$x_1^{(2)}$	\dots	$x_n^{(2)}$	$y_1^{(2)}$	\dots	$y_m^{(2)}$
\dots	\dots	\dots	\dots	\dots	\dots	\dots
$(x^{(N)}, y^{(N)})$	$x_1^{(N)}$	\dots	$x_n^{(N)}$	$y_1^{(N)}$	\dots	$y_m^{(N)}$

N es el número de patrones, n el número de características
y m el número de clases no excluyentes,

las características son variables binarias y las variables de clase también



Naïve Bayes



Formulación clásica de un problema de diagnóstico: Clases no excluyentes

$$(y_1^*, \dots, y_m^*) = \arg \max_{(y_1, \dots, y_m)} P(Y_1 = y_1, \dots, Y_m = y_m \mid X_1 = x_1, \dots, X_n = x_n)$$

$$\begin{aligned} P(Y_1 = y_1, \dots, Y_m = y_m \mid X_1 = x_1, \dots, X_n = x_n) &= \\ &= \frac{P((Y_1 = y_1, \dots, Y_m = y_m) \cap (X_1 = x_1, \dots, X_n = x_n))}{P(X_1 = x_1, \dots, X_n = x_n)} \propto \end{aligned}$$

$$\propto P(Y_1 = y_1, \dots, Y_m = y_m) P(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1, \dots, Y_m = y_m)$$

número de parámetros (probabilidades) a estimar: $2^m - 1 + 2^m(2^n - 1)$

m	n		<i>parámetros</i>
-----	-----	--	-------------------

3	10	$= 8191 \simeq$	8×10^3
---	----	-----------------	-----------------


5	20	\simeq	33×10^6
---	----	----------	------------------

10	50	\simeq	11×10^{17}
----	----	----------	---------------------

m es el número de clases no excluyentes y n el número de características



Naïve Bayes



Diagnósticos excluyentes, una sola clase de salida

$$c^* = \arg \max P(C = c \mid X_1 = x_1, \dots, X_n = x_n)$$

$$P(C = c \mid X_1 = x_1, \dots, X_n = x_n)$$

$$\propto P(C = c) P(X_1 = x_1, \dots, X_n = x_n \mid C = c)$$

número de parámetros a estimar: $(m - 1) + m(2^n - 1)$

m	n		<i>parámetros</i>
-----	-----	--	-------------------

3	10	\simeq	3×10^3
---	----	----------	-----------------

5	20	\simeq	5×10^6
---	----	----------	-----------------

10	50	\simeq	11×10^{15}
----	----	----------	---------------------

**m es el número de clases
excluyentes**

y n el número de características



Naïve Bayes



Diagnósticos excluyentes y variables condicionalmente independientes dado el diagnóstico (Naïve Bayes)

$$c^* = \arg \max_c P(C = c \mid X_1 = x_1, \dots, X_n = x_n) =$$
$$= \arg \max_c P(C = c) \prod_{i=1}^n P(X_i = x_i \mid C = c)$$

número de parámetros a estimar: $(m - 1) + mn$

m	n		<i>parámetros</i>
-----	-----	--	-------------------

3	10	\simeq	32
---	----	----------	----

5	20	\simeq	104
---	----	----------	-----

10	50	\simeq	509
----	----	----------	-----

m es el número de clases

excluyentes

y n el número de características



Naïve Bayes




Variables predictoras condicionalmente independientes dado que $C=c$

Predictoras discretas

$$c^* = \arg \max_c P(C = c) \cdot \prod_{i=1}^n P(X_i = x_i | C = c)$$

Predictoras continuas y normales

$$c^* = \arg \max_c P(C = c) \cdot \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma_i^c} e^{-\frac{1}{2}\left(\frac{x_i - \mu_i^c}{\sigma_i^c}\right)^2}$$



Estructura de un clasificador Naïve Bayes



Seminario Bayes: Pseudocódigo del algoritmo FSSJ (Pazzani, 1997)



Paso 1. Inicializar el conjunto de variables a utilizar a conjunto vacío.

Clasificar todos los ejemplos como pertenecientes a la clase más frecuente.

Paso 2. Repetir en cada paso la mejor opción entre:

(a) Considerar cada variable que no está en el modelo como una variable a incluir en el modelo. Dicha variable debe incluirse condicionalmente independiente de las variables presentes en el modelo, dada la variable clase.

(b) Juntar cada variable no presente en el modelo con una variable que ya forme parte del mismo.

Evaluar cada posible opción por medio de la estimación del porcentaje de patrones bien clasificados.

Hasta que ninguna opción produzca mejoras







Seminaïve Bayes



Proceso de construcción de un modelo seminaïve Bayes.

$$P(c|x, y, z, v) \propto P(c).P(z|c).P((y, v)|c)$$





Naïve Bayes aumentando el árbol



La cantidad de información mutua entre X e Y

$$I(X, Y) = \sum_{i=1}^{r_X} \sum_{j=1}^{r_Y} P(x_i, y_j) \log \frac{P(x_i, y_j)}{P(x_i) \cdot P(y_j)}$$

mide la reducción de la incertidumbre de una de las variables cuando se conoce la otra

Cantidad de información mutua entre X e Y condicionada a C

$$\begin{aligned} I(X, Y | C) &= \sum_c P(C = c) I(X, Y | C = c) \\ &= \sum_{i=1}^{r_X} \sum_{j=1}^{r_Y} \sum_{k=1}^{r_0} P(x_i, y_j, c_k) \log \frac{P(x_i, y_j | c_k)}{P(x_i | c_k) P(y_j | c_k)} \end{aligned}$$

Relación entre la cantidad de información mutua y las verosimilitudes o probabilidades condicionadas a c_k



Naïve Bayes aumentado en árbol



Pseudocódigo del algoritmo *TAN* (Friedman y col., 1997)

- Paso 1.** Calcular $I(X_i, X_j | C)$ con $i < j$, $i, j = 1, \dots, n$
- Paso 2.** Construir un grafo no dirigido completo cuyos nodos corresponden a las variables predictoras : X_1, \dots, X_n . Asignar a cada arista conectando las variables X_i y X_j un peso dado por $I(X_i, X_j | C)$
- Paso 3.** Asignar las dos aristas de mayor peso al árbol a construir
- Paso 4.** Examinar la siguiente arista de mayor peso, y añadirla al árbol a no ser que forme un ciclo, en cuyo caso se descarta y se examina la siguiente arista de mayor peso
- Paso 5.** Repetir el paso 4 hasta seleccionar $n - 1$ aristas
- Paso 6.** Transformar el árbol no dirigido resultante en uno dirigido, escogiendo una variable como raíz, para a continuación direccionar el resto de aristas
- Paso 7.** Construir un modelo *TAN* añadiendo un nodo etiquetado como C y posteriormente un arco desde C a cada variable predictora X_i











Naïve Bayes aumentado a árbol



Proceso de construcción de TAN. $I(X, Z | C) > I(Y, V | C) > I(X, Y | C) > I(Z, V | C) > I(X, V | C) > I(Z, W | C) > I(X, W | C) > I(Y, Z | C) > I(Y, W | C) > I(V, W | C)$

$$P(c|x, y, z, v, w) \propto P(c)P(x|c)P(y|x, c)P(z|x, c)P(v|y, c)P(w|z, c)$$





Clasificador Bayesiano k-dependiente



Clasificador Bayesiano k-dependiente (Sahami, 1996)

- Precalcula $I(X_i, C)$ y $I(X_i, X_j | C)$ para todo par de variables
- Añade en cada iteración, de entre las variables que no están en el modelo, aquella X_{max} que tenga mayor $I(X_i, C)$
- Asigna a la variable añadida como padres la variable C y aquellas k variables con mayor $I(X_j, X_{max} | C)$



Clasificador Bayesiano k-dependiente





Proceso de construcción de kDB con $k = 2$.

$$I(X_3, C) > I(X_1, C) > I(X_4, C) > I(X_5, C) > I(X_2, C)$$

$$I(X_3, X_4 | C) > I(X_2, X_5 | C) > I(X_1, X_3 | C) > I(X_1, X_2 | C) > I(X_2, X_4 | C) >$$

$$I(X_2, X_3 | C) > I(X_1, X_4 | C) > I(X_4, X_5 | C) > I(X_1, X_5 | C) > I(X_3, X_5 | C)$$





Clasificador Bayesiano k-dependiente





Proceso de construcción de kDB con $k = 2$.

$$I(X_3, C) > I(X_1, C) > I(X_4, C) > I(X_5, C) > I(X_2, C)$$

$$I(X_3, X_4 | C) > I(X_2, X_5 | C) > I(X_1, X_3 | C) > I(X_1, X_2 | C) > I(X_2, X_4 | C) >$$

$$I(X_2, X_3 | C) > I(X_1, X_4 | C) > I(X_4, X_5 | C) > I(X_1, X_5 | C) > I(X_3, X_5 | C)$$

$$P(c | x_1, x_2, x_3, x_4, x_5)$$





Clasificador Bayesiano k-dependiente



Proceso de construcción de **kDB** con **k = 2**.



$$I(X_3, C) > I(X_1, C) > I(X_4, C) > I(X_5, C) > I(X_2, C)$$

$$I(X_3, X_4 | C) > I(X_2, X_5 | C) > I(X_1, X_3 | C) > I(X_1, X_2 | C) > I(X_2, X_4 | C) >$$

$$I(X_2, X_3 | C) > I(X_1, X_4 | C) > I(X_4, X_5 | C) > I(X_1, X_5 | C) > I(X_3, X_5 | C)$$

$$p(c|x_1, x_2, x_3, x_4, x_5) \propto$$

$$p(c)p(x_1|x_3, c)p(x_2|x_1, x_5, c)p(x_3|c)p(x_4|x_1, x_3, c)p(x_5|x_1, x_4, c)$$





Tutorial de Weka

Clasificador Naïve Bayes

Naive Bayes (NB) (Maron and Kuhns, 1960)





Clasificador OneR

¿Cuál es el mejor predictor?



Outlook	Temp.	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy				yes
sunny				yes
overcast				yes
overcast				yes
rainy				no

=== Classifier model (full training set) ===

Regla
OneR

Outlook:

IF sunny -> no

IF overcast -> yes

IF rainy -> yes

(10/14 instances correct)

3 aciertos

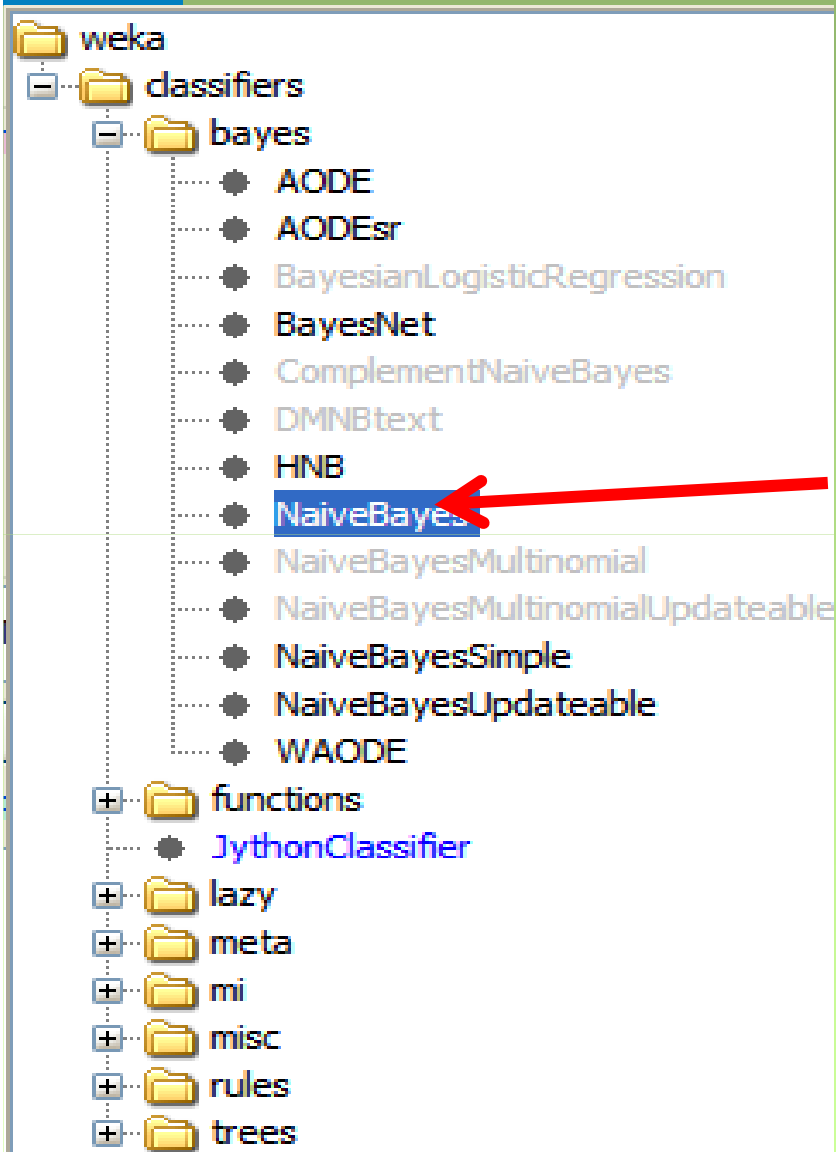
3 aciertos

4 aciertos

Total 10 de 14



Clasificador Bayesiano



Es suficiente utilizar la regla OneR o es mejor utilizar el algoritmo naïvë Bayes



Clasificador Bayesiano



Como de bien el atributo aspecto del cielo
“Outlook” Nublado, predice si jugar o no a tenis?

Outlook	Temp.	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	h			no
overcast	h			yes
rainy	m			yes
rainy	c			yes
rainy	c			no
overcast	c			yes
sunny	m			no
sunny	c			yes
rainy	m			yes
sunny	m			yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

Outlook	yes	no
sunny	2	3
overcast	4	0
rainy	3	2
TOTAL	9	5




Clasificador Bayesiano



	Play	
Outlook	yes	no
sunny	2	3
overcast	4	0
rainy	3	2
TOTAL	9	5

Repetirlo con todos los atributos...



Estructura del clasificador Naïve Bayes

	Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		yes	no
sunny	2	3	hot	2	2	high	3	4	false	6	2	yes	9	
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5	
rainy	3	2	cool	3	1									
TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	14	

Clasificador Bayesiano

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	2	3	hot	2	2	high	3	4	false	6	2	yes	9
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5
rainy	3	2	cool	3	1								
TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	14

$P(\text{Outlook} = \text{Sunny} \mid \text{PlayGolf} = \text{Yes})$
 $= 2/9 = 0.22$

Convertir los valores a proporciones o probabilidades

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.22	0.60	hot	0.22	0.40	high	0.33	0.80	false	0.67	0.40	yes	0.64
overcast	0.44	0.00	mild	0.44	0.40	normal	0.67	0.20	true	0.33	0.60	no	0.36
rainy	0.33	0.40	cool	0.33	0.20								

$2/5 = 0.40$

2 casos de Play = no, dado que Outlook = rainy (casos favorables)
 5 casos de Play = no (casos posibles)



Clasificador Bayesiano



Ejemplo: Calcular la verosimilitud de NO JUGAR bajo estas condiciones atmosféricas:

Outlook = sunny (0.60)

Temperature = cool (0.20)

Humidity = high (0.80)

Windy = true (0.60)

Play = no (0.36)

$$0.60 \times 0.20 \times 0.80 \times 0.60 \times 0.36 = 0.0206$$

Verosimilitud de NO JUGAR bajo las condiciones atmosféricas dadas, bajo la hipótesis de que son sucesos condicionalmente independientes.

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.22	0.60	hot	0.22	0.40	high	0.33	0.80	false	0.67	0.40	yes	0.64
overcast	0.44	0.00	mild	0.44	0.40	normal	0.67	0.20	true	0.33	0.60	no	0.36
rainy	0.33	0.40	cool	0.33	0.20								



Clasificador Bayesiano



Probabilidad de jugar y de no jugar bajo las siguientes condiciones atmosféricas:

Dadas las siguientes condiciones atmosféricas:

Outlook = sunny

Temperature = cool

Humidity = high

Windy = true

Probabilidad de **Play = yes**:

$$\frac{0.0053}{0.0053 + 0.0206} = 20.5\%$$

↑
Cálculo de las
verosimilitudes

Probabilidad de **Play = no**:

$$\frac{0.0206}{0.0053 + 0.0206} = 79.5\%$$



Ejemplo



Verosimilitud de NO jugar bajo estas condiciones atmosféricas:

Calcular la verosimilitud de que

Outlook = overcast (0.00)

Temperature = cool (0.20)

Humidity = high (0.80)

Windy = true (0.60)

Play = no (0.36)

El juego nunca fué cancelado en un día nublado

$$0.00 \times 0.20 \times 0.80 \times 0.60 \times 0.36 = 0.0000$$

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.22	0.60	hot	0.22	0.40	high	0.33	0.80	false	0.67	0.40	yes	0.64
overcast	0.44	0.00	mild	0.44	0.40	normal	0.67	0.20	true	0.33	0.60	no	0.36
rainy	0.33	0.40	cool	0.33	0.20								



Counts - from dataset

Outlook	Play		Temp.	Play		Humid.	Play		Windy	Play			Play
	yes	no		yes	no		yes	no		yes	no		
sunny	2	3	hot	2	2	high	3	4	false	6	2	yes	9
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5
rainy	3	2	cool	3	1								
TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	14


estimador de Laplace:
Añadir una unidad a cada valor

Add 1 to count (Laplace estimator)

Outlook	Play		Temp.	Play		Humid.	Play		Windy	Play			Play
	yes	no		yes	no		yes	no		yes	no		
sunny	3	4	hot	3	3	high	4	5	false	7	3	yes	12
overcast	5	1	mild	5	3	normal	7	2	true	4	4	no	8
rainy	4	3	cool	4	2								
TOTAL	12	8	TOTAL	12	8	TOTAL	11	7	TOTAL	11	7	TOTAL	20



	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	3	4	hot	3	3	high	4	5	false	7	3	yes	9
overcast	5	1	mild	5	3	normal	7	2	true	4	4	no	5
rainy	4	3	cool	4	2								
TOTAL	12	8	TOTAL	12	8	TOTAL	11	7	TOTAL	11	7	TOTAL	14




Convertir los valores incrementados a proporciones o probabilidades

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.25	0.50	hot	0.25	0.38	high	0.36	0.71	false	0.64	0.43	yes	0.64
overcast	0.42	0.13	mild	0.42	0.38	normal	0.64	0.29	true	0.36	0.57	no	0.36
rainy	0.33	0.38	cool	0.33	0.25								

Se mantienen las probabilidades de pertenencia a cada clase



Con estimador de Laplace



	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.25	0.50	hot	0.25	0.38	high	0.36	0.71	false	0.64	0.43	yes	0.64
overcast	0.42	0.13	mild	0.42	0.38	normal	0.64	0.29	true	0.36	0.57	no	0.36
rainy	0.33	0.38	cool	0.33	0.25								

Outlook = overcast, Temperature = cool, Humidity = high,
Windy = true

Verosimilitud

$$\text{Play} = \text{no}: 0.13 \times 0.25 \times 0.71 \times 0.57 \times 0.36 = 0.0046$$

$$\text{Play} = \text{yes}: 0.42 \times 0.33 \times 0.36 \times 0.36 \times 0.64 = 0.0118$$

$$\text{Probabilidad de Play} = \text{no}: \frac{0.0046}{0.0046 + 0.0118} = 28\%$$

$$\text{Probabilidad de Play} = \text{yes}: \frac{0.0118}{0.0046 + 0.0118} = 72\%$$

Previamente
100%, porque
la
probabilidad
de No jugar
era 0



Con estimador de Laplace



	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.25	0.50	hot	0.25	0.38	high	0.36	0.71	false	0.64	0.43	yes	0.64
overcast	0.42	0.13	mild	0.42	0.38	normal	0.64	0.29	true	0.36	0.57	no	0.36
rainy	0.33	0.38	cool	0.33	0.25								

Outlook = sunny, Temperature = cool, Humidity = high, Windy = true

Verosimilitud

Play = no: $0.50 \times 0.25 \times 0.71 \times 0.57 \times 0.36 = 0,0182115$

Play = yes: $0.25 \times 0.33 \times 0.36 \times 0.36 \times 0.64 = 0,00684288$

Probabilidad de Play = no: $\frac{0.0182115}{0.0182115 + 0.00684288} = 72,68\%$

Probabilidad de Play = yes: $\frac{0.00684288}{0.00684288 + 0.0182115} = 27,31\%$



Probabilidad de jugar y de no jugar bajo las siguientes condiciones atmosféricas:



Dado:

Outlook = **sunny**

Temperature = cool

Humidity = high

Windy = true

Sin utilizar el estimador de Laplace

Play = no: 79.5%

Play = yes: 20.5%



Utilizando el estimador de Laplace

Play = no: 72.68%

Play = yes: 27,31%

En ambos casos la regla equivalente es la misma:

IF Outlook = sunny

AND Temperature = cool

AND Humidity = high

AND Windy = true

THEN Play = no.

Verdadero
utilizando
ambos cálculos



Dado:

Outlook = sunny

Temperature = cool

Humidity = high

Windy = true

Pregunta: Jugaran a tenis?



Dos posibles reglas:

- **Regla 1: Si Outlook = sunny Y Temperature = cool Y Humidity = high Y Windy = true, Entonces Play = no.**
- **Regla 2: Si Outlook = sunny Y Temperature = cool Y Humidity = high Y Windy = true, Entonces Play = yes.**

Probabilidades de que las reglas sean correctas :

- **Regla 1 = 72%**
- **Regla 2 = 28%**

Por tanto: Utilizar la Regla 1 para estas condiciones meteorológicas.

Ahora se repite para todas las otras combinaciones de condiciones



Outlook	Temp.	Humid.	Windy	Play
overcast	cool	high	false	no
overcast	cool	high	false	yes
overcast	cool	high	true	no
overcast	cool	high	true	yes
overcast	cool	normal	false	no
overcast	cool	normal	false	yes
overcast	cool	normal	true	no
overcast	cool	normal	true	yes
overcast	hot	high	false	no
overcast	hot	high	false	yes
overcast	hot	high	true	no
overcast	hot	high	true	yes
overcast	hot	normal	false	no
overcast	hot	normal	false	yes
overcast	hot	normal	true	no
overcast	hot	normal	true	yes

Repetir todos los cálculos anteriores para todas las posibles combinaciones de condiciones atmosféricas



	Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no			
sunny	0.25	0.50	hot	0.25	0.38	high	0.36	0.71	false	0.64	0.43	yes	0.64	
overcast	0.42	0.13	mild	0.42	0.38	normal	0.64	0.29	true	0.36	0.57	no	0.36	
rainy	0.33	0.38	cool	0.33	0.25									




Calculo de las probabilidades de las 36 posibles combinaciones=3x3x2x2

Inst	Outlook	Temp.	Humid.	Windy	Play	Outlook	Temp.	Humid.	Windy	Play	Like.	Prob.
	overcast	cool	high	false	no	0.13	0.25	0.71	0.43	0.36	0.0034	14.2%
	overcast	cool	high	false	yes	0.42	0.33	0.36	0.64	0.64	0.0207	85.8%
	overcast	cool	high	true	no	0.13	0.25	0.71	0.57	0.36	0.0046	27.8%
	overcast	cool	high	true	yes	0.42	0.33	0.36	0.36	0.64	0.0118	72.2%
	overcast	cool	normal	false	no	0.13	0.25	0.29	0.43	0.36	0.0014	3.6%
	overcast	cool	normal	false	yes	0.42	0.33	0.64	0.64	0.64	0.0362	96.4%
	overcast	cool	normal	true	no	0.13	0.25	0.29	0.57	0.36	0.0018	8.1%
7	overcast	cool	normal	true	yes	0.42	0.33	0.64	0.36	0.64	0.0207	91.9%
	overcast	hot	high	false	no	0.13	0.38	0.71	0.43	0.36	0.0051	24.9%
3	overcast	hot	high	false	yes	0.42	0.25	0.36	0.64	0.64	0.0155	75.1%



Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.
	overcast	cool	normal	false	yes	96.4%
	overcast	mild	normal	false	yes	95.7%
13	overcast	hot	normal	false	yes	93.0%
7	overcast	cool	normal	true	yes	91.9%
	overcast	mild	normal	true	yes	90.4%
5	rainy	cool	normal	false	yes	87.6%
	overcast	cool	high	false	yes	85.8%
10	rainy	mild	normal	false	yes	85.5%
	overcast	hot	normal	true	yes	85.0%
2	sunny	hot	high	true	no	83.7%
	overcast	mild	high	false	yes	83.4%
9	sunny	cool	normal	false	yes	79.9%
	rainy	hot	normal	false	yes	77.9%
	sunny	mild	normal	false	yes	76.8%
	sunny	mild	high	true	no	75.5%
3	overcast	hot	high	false	yes	75.1%
	rainy	cool	normal	true	yes	75.1%
	rainy	hot	high	true	no	74.3%

**Reglas de predicción de clase
para todas las
combinaciones de atributos.**



Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.
	overcast	cool	high	true	yes	72.2%
	sunny	cool	high	true	no	72.0%
	rainy	mild	normal	true	yes	71.6%
1	sunny	hot	high	false	no	68.8%
12	overcast	mild	high	true	yes	68.4%
	sunny	hot	normal	false	yes	66.5%
14	rainy	mild	high	true	no	63.5%
	sunny	cool	normal	true	yes	63.0%
	rainy	cool	high	false	yes	61.7%
	rainy	hot	normal	true	yes	60.2%
	rainy	cool	high	true	no	59.1%
11	sunny	mild	normal	true	yes	58.6%
4	rainy	mild	high	false	yes	57.3%
8	sunny	mild	high	false	no	57.0%
	overcast	hot	high	true	yes	56.4%
	rainy	hot	high	false	no	55.4%
	sunny	hot	normal	true	no	54.0%
	sunny	cool	high	false	no	52.4%

**¿Donde esta la
instancia 6?**



Comparación de decisiones predichas y actuales (o reales)



Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.	Actual
1	sunny	hot	high	false	no	72.6%	no
2	sunny	hot	high	true	no	86.1%	no
3	overcast	hot	high	false	yes	71.6%	yes
4	rainy	mild	high	false	yes	52.8%	yes
5	rainy	cool	normal	false	yes	85.5%	yes
6	rainy	cool	normal	true	yes	75.1%	no
7	overcast	cool	normal	true	yes	90.4%	yes
8	sunny	mild	high	false	no	61.4%	no
9	sunny	cool	normal	false	yes	76.8%	yes
10	rainy	mild	normal	false	yes	83.0%	yes
11	sunny	mild	normal	true	yes	54.2%	yes
12	overcast	mild	high	true	yes	64.3%	yes
13	overcast	hot	normal	false	yes	91.7%	yes
14	rainy	mild	high	true	no	67.6%	no



Weka Explorer

Preprocess Classify Cluster Associate

Classifier

Choose **NaiveBayes**

Test options

☒ Use training set

☐ Supplied test set Set...

☐ Cross-validation Folds 10

☐ Percentage split % 66

Classifier evaluation options

☒ Output model

☒ Output per-class stats

☐ Output entropy evaluation measures

☒ Output confusion matrix

☒ Store predictions for visualization

Output predictions Choose **PlainText**

weka.gui.GenericObjectEditor

weka.classifiers.bayes.NaiveBayes

About

Class for a Naive Bayes classifier using estimated probabilities

debug False

displayModelInOldFormat False

useKernelEstimator False

useSupervisedDiscretization False

Open... Save...

Ejecutar el clasificador naïve Bayes de Weka sobre la base de datos To-Play-Or-Not-To-Play



Add 1 to count (Laplace estimator)

Outlook	Play		Temp.	Play		Humid.	Play		Windy	Play			Play
	yes	no		yes	no		yes	no		yes	no		
sunny	3	4	hot	3	3	high	4	5	false	7	3	yes	12
overcast	5	1	mild	5	3	normal	7	2					
rainy	4	3	cool	4	2								
TOTAL	12	8	TOTAL	12	8	TOTAL	11	7					

Classifier output

Attribute	no (0.38)	yes (0.63)
=====		
Outlook		
sunny	4.0	3.0
overcast	1.0	5.0
rainy	3.0	4.0
[total]	8.0	12.0

Temp.		
hot	3.0	3.0
mild	3.0	5.0
cool	2.0	4.0
[total]	8.0	12.0

Humidity		
high	5.0	4.0
normal	2.0	7.0
[total]	7.0	11.0

**El clasificador ha
utilizado el estimador de
Laplace**



El clasificador naïve Bayes clasifica mal la instancia o patrón 6

Classifier output

=== Predictions on training set ===

inst#	actual	predicted	error	prediction
1	1:no	1:no		0.704
2	1:no	1:no		0.847
3	2:yes	2:yes		0.737
4	2:yes	2:yes		0.554
5	2:yes	2:yes		0.867
6	1:no	2:yes	+	0.737
7	2:yes	2:yes		0.913
8	1:no	1:no		0.588
9	2:yes	2:yes		0.786
10	2:yes	2:yes		0.845
11	2:yes	2:yes		0.568
12	2:yes	2:yes		0.667
13	2:yes	2:yes		0.925
14	1:no	1:no		0.652

Errores de predicción



Salida del clasificador o “prediction”

Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.	Actual
1	sunny	hot	high	false	no	72.6%	no
2	sunny	hot	high	true	no	86.1%	no
3	overcast	hot	high	false	yes	71.6%	yes
4	rainy	mild	high	false	yes	52.8%	yes
5	rainy	cool	normal	false	yes	85.5%	yes
6	rainy	cool	normal	true	yes	75.1%	no
7	overcast	cool	normal	true	yes	90.4%	yes
8	sunny	mild	high	false	no	61.4%	no
9	sunny	cool	normal	false	yes	76.8%	yes
10	rainy	mild	normal	false	yes	83.0%	yes
11	sunny	mild	normal	true	yes	54.2%	yes
12	overcast	mild	high	true	yes	64.3%	yes
13	overcast	hot	normal	false	yes	91.7%	yes
14	rainy	mild	high	true	no	67.6%	no

Classifier output

=== Predictions on training set ===


inst#	actual	predicted error	prediction
1	1:no	1:no	0.704
2	1:no	1:no	0.847
		2:yes	0.737
		2:yes	0.554
		2:yes	0.867
		2:yes +	0.737
		2:yes	0.913
		1:no	0.588
		2:yes	0.786
		2:yes	0.845
		2:yes	0.568
		2:yes	0.667
		2:yes	0.925
		1:no	0.652



Cuestiones críticas de minería de datos:

- **Cómo aplicar los clasificadores.**
- **Mantener el modelo lo más sencillo posible**
- **Discretización.**
- **Impacto de los valores perdidos.**


**Como aborda estas
cuestiones el clasificador
Naive Bayes**



¿Dónde está el modelo equivalente al clasificador Naïve Bayes de Weka?

```
=== Classifier model (full training set) ===  
  
Outlook:  
    sunny    -> no  
    overcast          -> yes  
    rainy    -> yes  
(10/14 instances correct)
```

**Conjunto de reglas
generado por OneR de
Weka**



Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.
	overcast	cool	normal	false	yes	96.4%
	overcast	mild	normal	false	yes	95.7%
13	overcast	hot	normal	false	yes	93.0%
7	overcast	cool	normal	true	yes	91.9%
	overcast	mild	normal	true	yes	90.4%
5	rainy	cool	normal	false	yes	87.6%
	overcast	cool	high	false	yes	87.0%
10	rainy	mild	normal	false	yes	86.3%
	overcast	hot	normal	false	yes	85.0%
2	sunny	hot	high	false	no	83.9%
	overcast	mild	high	false	yes	83.4%
9	sunny	cool	normal	false	yes	79.9%
	rainy	hot	normal	false	yes	77.9%
	sunny	mild	normal	false	yes	76.8%
	sunny	mild	high	true	no	75.5%
3	overcast	hot	high	false	yes	75.1%
	rainy	cool	normal	true	yes	75.1%
	rainy	hot	high	true	no	74.3%

**Reglas que predicen la
clase para todas la
combinaciones de atributos**

Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.
	overcast	cool	high	true	yes	72.2%
	sunny	cool	high	true	no	72.0%
	rainy	mild	normal	true	yes	71.6%
1	sunny	hot	high	false	no	68.8%
12	overcast	mild	high	true	yes	68.4%
	rainy	cool	normal	false	yes	66.5%
	overcast	cool	high	true	no	63.5%
	rainy	mild	normal	true	yes	63.0%
	overcast	hot	high	false	yes	61.7%
	rainy	cool	high	true	no	59.1%
11	sunny	mild	normal	true	yes	58.6%
4	rainy	mild	high	false	yes	57.3%
8	sunny	mild	high	false	no	57.0%
	overcast	hot	high	true	yes	56.4%
	rainy	hot	high	false	no	55.4%
	sunny	hot	normal	true	no	54.0%
	sunny	cool	high	false	no	52.4%

**Una aplicación con 5 atributos cada uno de
ellos con 5 valores tendría 3125 reglas!**



	Play			Play			Play			Play			Play
Outlook	yes	no	Temp	yes	no	Humid	yes	no	Windy	yes	no		
sunny	3	4	hot	3	3	high	4	5	false	7	3	yes	9
overcast	5	1	mild	5	3	normal	7	2	true	4	4	no	5
rainy	4	3	cool	4	2								
TOTAL	12	8	TOTAL	12	8	TOTAL	11	7	TOTAL	11	7	TOTAL	14

Conjunto de datos
historicos de
decisiones
tomadas

Retroalimentar
los resultados

Predecir en función de
las condiciones
atmosféricas de hoy:
sunny, hot, high, false

Calcular
probabilidades

No
play!

Nueva instancia de
condiciones
atmosféricas

Calculo de
probabilidades
genérico Naïve Bayes



Cuestiones críticas de minería de datos:

- **Cómo aplicar los clasificadores.**
- **Mantener el modelo lo más sencillo posible**
- **Discretización.**
- **Impacto de los valores perdidos.**



¿Que es “ingenuo” del clasificador ingenuo Bayes “Naïvë Bayes”?

Respuesta sencilla: atributos
o variables aleatorias
condicionalmente
Independientes

Respuesta no tan
sencilla : teorema de
Bayes

Que significa
esto?



Energía solar para sistema de sonido



Outlook	Power
sunny	high
overcast	medium
rainy	low



Outlook	Power
sunny	high
overcast	medium
rainy	low

Añadir un nuevo atributo

**El atributo
Potencia es una
variable
dependiente del
estado del cielo o
“Outlook”**

Outlook	Temp.	Humidity	Windy	Power	Play
sunny	hot	high	false	high	no
sunny	hot	high	true	high	no
overcast	hot	high	false	medium	yes
rainy	mild	high	false	low	yes
rainy	cool	normal	false	low	yes
rainy	cool	normal	true	low	no
overcast	cool	normal	true	medium	yes
sunny	mild	high	false	high	no
sunny	cool	normal	false	high	yes
rainy	mild	normal	false	low	yes
sunny	mild	normal	true	high	yes
overcast	mild	high	true	medium	yes
overcast	hot	normal	false	medium	yes
rainy	mild	high	true	low	no



Añadir el
atributo
potencia

Add 1 to count (Laplace estimator)

	Play			Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no	Power	yes	no			
sunny	3	4	hot	3	3	high	4	5	false	7	3	high	3	4	yes	9	
overcast	5	1	mild	5	3	normal	7	2	true	4	4	medium	5	1	no	5	
rainy	4	3	cool	4	2							low	4	3			
TOTAL	12	8	TOTAL	12	8	TOTAL	11	7	TOTAL	11	7	TOTAL	12	8	TOTAL	14	

Ratios

	Play			Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no	Power	yes	no			
sunny	0.25	0.50	hot	0.25	0.38	high	0.36	0.71	false	0.64	0.43	high	0.25	0.50	yes	0.64	
overcast	0.42	0.13	mild	0.42	0.38	normal	0.64	0.29	true	0.36	0.57	medium	0.42	0.13	no	0.36	
rainy	0.33	0.38	cool	0.33	0.25							low	0.33	0.38			

Salida de los porcentajes de
potencia



SIN Atributo Potencia

Para Play = yes (.64)

Outlook = overcast (.42)

Temperature = cool (.33)

Humidity = high (.36)

Windy = true (.36)

Verosimilitud = $0.42 * 0.33 * 0.36 * 0.36 * 0.64 = 0.0118$



CON Atributo Potencia

Para Play = yes (.64)

Outlook = overcast (.42)

Temperature = cool (.33)

Humidity = high (.36)

Windy = true (.36)

→ Power = medium (.42)

Verosimilitud = $0.42 * 0.33 * 0.36 * 0.36 * 0.42 * 0.64 = 0.00496$

El efecto de la variable Outlook se aplica dos veces



Nuevas condiciones atmosféricas

Outlook = overcast
Temperature = cool
Humidity = high
Windy = true
Power = medium



SIN Atributo Potencia

$$\text{Probabilidad de Play = no: } \frac{0.046}{0.0046 + 0.0118} = 28\%$$

$$\text{Probabilidad de Play = yes: } \frac{0.0118}{0.0046 + 0.0118} = 72\%$$

CON Atributo Potencia

$$\text{Probabilidad de Play = no: } \frac{0.00060}{0.00060 + 0.00496} = 10\%$$

$$\text{Probabilidad de Play = yes: } \frac{0.00496}{0.00060 + 0.00496} = 90\%$$



Las primeras 18 reglas son las mismas cuando utilizamos atributos dependientes



					NO Power			WITH Power		
Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.	Err	Play	Prob.	Err
	overcast	cool	high	false	yes	85.8%		yes	95.3%	
	overcast	cool	high	true	yes	72.2%		yes	89.6%	
	overcast	cool	normal	false	yes	96.4%		yes	98.9%	
7	overcast	cool	normal	true	yes	91.9%		yes	97.4%	
3	overcast	hot	high	false	yes	75.1%		yes	91.0%	
	overcast	hot	high	true	yes	56.4%		yes	81.2%	
13	overcast	hot	normal	false	yes	93.0%		yes	97.8%	
	overcast	hot	normal	true	yes	85.0%		yes	95.0%	
	overcast	mild	high	false	yes	83.4%		yes	94.4%	
12	overcast	mild	high	true	yes	68.4%		yes	87.8%	
	overcast	mild	normal	false	yes	95.7%		yes	98.7%	
	overcast	mild	normal	true	yes	90.4%		yes	96.9%	
	rainy	cool	high	false	yes	61.7%		yes	58.9%	
	rainy	cool	high	true	no	59.1%		no	61.9%	
5	rainy	cool	normal	false	yes	87.6%		yes	86.2%	
6	rainy	cool	normal	true	yes	75.1%	+	yes	72.9%	+
	rainy	hot	high	false	no	55.4%		no	58.3%	
	rainy	hot	high	true	no	74.3%		no	76.5%	



Las últimas 18 tienen algunas diferencias sobre las reglas de menor probabilidad



					NO Power			WITH Power		
Inst	Outlook	Temp.	Humid.	Windy	Play	Prob.	Err	Play	Prob.	Err
	rainy	hot	normal	false	yes	77.9%		yes	75.8%	
	rainy	hot	normal	true	yes	60.2%		yes	57.3%	
4	rainy	mild	high	false	yes	57.3%		yes	54.4%	
14	rainy	mild	high	true	no	63.5%		no	66.1%	
10	rainy	mild	normal	false	yes	85.5%		yes	83.9%	
	rainy	mild	normal	true	yes	71.6%		yes	69.1%	
	sunny	cool	high	false	no	52.4%		no	68.8%	
	sunny	cool	high	true	no	72.0%		no	83.7%	
9	sunny	cool	normal	false	yes	79.9%		yes	66.5%	
	sunny	cool	normal	true	yes	63.0%		no	54.0%	
1	sunny	hot	high	false	no	68.8%		no	81.5%	
2	sunny	hot	high	true	no	83.7%		no	91.1%	
	sunny	hot	normal	false	yes	66.5%		no	50.2%	
	sunny	hot	normal	true	no	54.0%		no	70.2%	
8	sunny	mild	high	false	no	57.0%		no	72.6%	
	sunny	mild	high	true	no	75.5%		no	86.1%	
	sunny	mild	normal	false	yes	76.8%		yes	62.3%	
11	sunny	mild	normal	true	yes	58.6%		no	58.5%	+



**¿Porqué OneR
trabaja tan
bien?**

**Entonces ¿por
qué Naïvë Bayes
trabaja tan bien?**

**Por qué buscar un
clasificador que sea sencillo
es a menudo la mejor política**

**Porque a menudo
la clase tiempo
está dominada por
un solo atributo**

**Debido a que no se
preocupa por las
probabilidades, sólo
queremos saber si
debemos ir a jugar!**

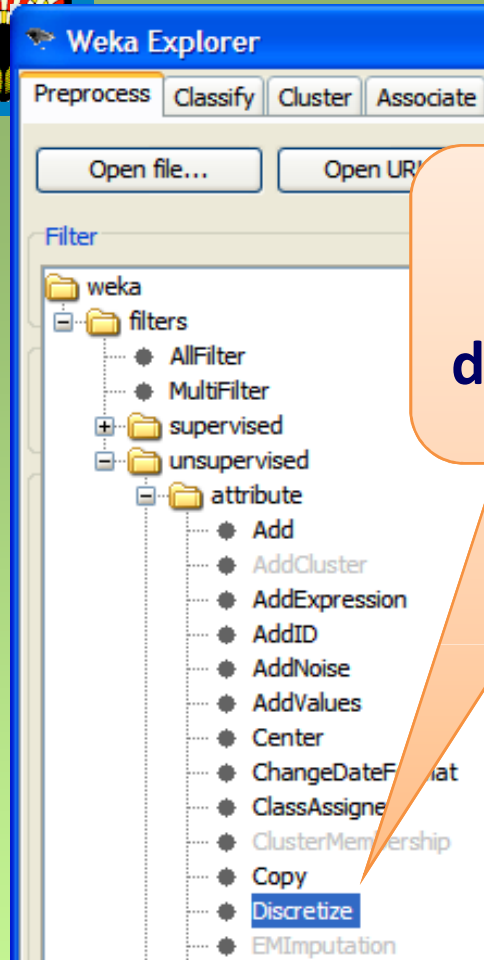


Cuestiones críticas de minería de datos:

- **Cómo aplicar los clasificadores.**
- **Mantener el modelo lo más sencillo posible**
- **Discretización.**
- **Impacto de los valores perdidos.**

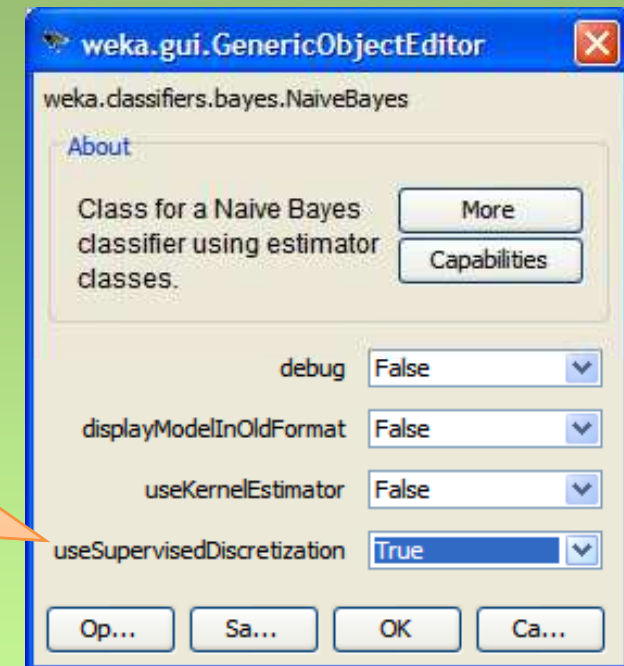


Como se pueden utilizar atributos numéricos en el clasificador naïve Bayes?



**Opción 1:
Utilizar
discretización no
supervisada**

**Opción 2:
Utilizar
discretización
supervisada**



**Opción 3: Utilizar la capacidad de
construir atributos numéricos de
NaiveBayes de Weka**



	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	2	3	hot	2	2	high	3	4	false	6	2	yes	9
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5
rainy	3	2	cool	3	1								
TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	14


**Empezar contando las
ocurrencias de los
sucesos (frecuencias
absolutas)**

**Pasar las
frecuencias
absolutas a
probabilidades**

	Play			Play			Play			Play			Play
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		
sunny	0.22	0.60	hot	0.22	0.40	high	0.33	0.80	false	0.67	0.40	yes	0.64
overcast	0.44	0.00	mild	0.44	0.40	normal	0.67	0.20	true	0.33	0.60	no	0.36
rainy	0.33	0.40	cool	0.33	0.20								



Calculo de las probabilidades a partir de atributos numéricos



$$\frac{1}{\sigma(2\pi)^{1/2}} \exp \left(-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right)$$

Frecuencia de las Ocurrencias

Calcular las probabilidades a partir de una distribución Normal (μ, σ)

μ
media

σ
desviación típica

Suponemos que la Temperatura y la Humedad son atributos numéricos que siguen una distribución Normal (μ, σ)

x



Play =	Temperature	
	Yes	No
	83	85
	70	80
	68	65
	64	72
	69	71
	75	
	75	
	72	
	81	
Mean =	73.0	74.6
S.D. =	6.2	7.9



$$\frac{1}{\sigma(2\pi)^{1/2}} \exp \left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right)$$

$$\frac{1}{6.2(2\pi)^{1/2}} \exp \left(-\frac{1}{2} \left(\frac{66 - 73.0}{6.2} \right)^2 \right) = 0.0340$$

Calcular la probabilidad de que Temp. = 66 cuando Play = yes



	Temperature	
Play =	Yes	No
	83	85
	70	80
	68	65
	64	72
	69	71
	75	
	75	
	72	
	81	
Mean =	73.0	74.6
S.D. =	6.2	7.9
@ Temp. = 66	0.0340	0.0279

	Humidity	
Play =	Yes	No
	86	85
	96	90
	80	70
	65	95
	70	91
	80	
	70	
	90	
	75	
Mean =	79.1	86.2
S.D. =	10.2	9.7
@ Humid. = 90	0.0221	0.0380



Verosimilitud de Play = yes para atributos nominales y numéricos




Con todos los atributos nominales:

Outlook = sunny (.22)

Temperature = cool (.33)

Humidity = high (.33)

Windy = true (.33)

Play = yes (.64)  $.22 \times .33 \times .33 \times .33 \times .64 = \mathbf{0.0053}$

Con atributos numéricos para Temperature = 66 y Humidity = 90:

Outlook = sunny (.22)

Temperature = **66 (.0340)**

Humidity = **90 (.0221)**

Windy = true (.33)

Play = yes (.64)  $.22 \times .\mathbf{0340} \times .\mathbf{0221} \times .33 \times .64 = \mathbf{0.000036}$



Verosimilitud de Play = no para atributos nominales y numéricos



Con todos los atributos nominales:

Outlook = sunny (.60)

Temperature = cool (.20)

Humidity = high (.80)

Windy = true (.60)

Play = no (.36) → $.60 \times .20 \times .80 \times .60 \times .36 = 0.0206$

Con atributos numéricos para Temperature = 66 y Humidity = 90:

Outlook = sunny (.60)

Temperature = **66 (.0279)**

Humidity = **90 (.0380)**

Windy = true (.60)

Play = no (.36) → $.60 \times .0279 \times .0380 \times .60 \times .36 = 0.000137$



Probabilidad de jugar y de no jugar bajo ciertas condiciones atmosféricas



Dadas estas condiciones atmosféricas y suponiendo distribuciones de probabilidad normales para la temperatura y humedad tenemos:

Outlook = sunny

Temperature = 66

Humidity = 90

Windy = true

$$\text{Probabilidad de Play = yes: } \frac{0.000036}{0.000036 + 0.000137} = 20.8\%$$

$$\text{Probabilidad de Play = no: } \frac{0.000137}{0.000036 + 0.000137} = 79.2\%$$



Cuestiones críticas de minería de datos:

- **Cómo aplicar los clasificadores.**
- **Mantener el modelo lo más sencillo posible**
- **Discretización.**
- **Impacto de los valores perdidos.**



Outlook	Temp.	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild		false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

Con fines ilustrativos,
eliminamos un valor de
Outlook = soleado y un valor
de
Humedad = alta

Un recuento de
menos debido a la
falta de un valor

	Play			Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no		yes	no		yes	no
sunny	1	3	hot	2	2	high	2	4	false	6	2	yes	9				
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5				
rainy	3	2	cool	3	1												
TOTAL	8	5	TOTAL	9	5	TOTAL	8	5	TOTAL	9	5	TOTAL	14				



Counts - no missing data

	Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no			
sunny	2	3	hot	2	2	high	3	4	false	6	2	yes	9	
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5	
rainy	3	2	cool	3	1									
TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	9	5	TOTAL	14	

Counts - with missing data

	Play			Play			Play			Play			Play	
Outlook	yes	no	Temp.	yes	no	Humid.	yes	no	Windy	yes	no			
sunny	1	5	hot	2	2	high	2	4	false	6	2	yes	9	
overcast	4	0	mild	4	2	normal	6	1	true	3	3	no	5	
rainy	3	2	cool	3	1									
TOTAL	8	5	TOTAL	9	5	TOTAL	8	5	TOTAL	9	5	TOTAL	14	



APRENDIZAJE AUTOMÁTICO: TERCER CURSO DEL GRADO DE ING. INFORMÁTICA EN COMPUTACION

Clasificación: Redes Bayesianas

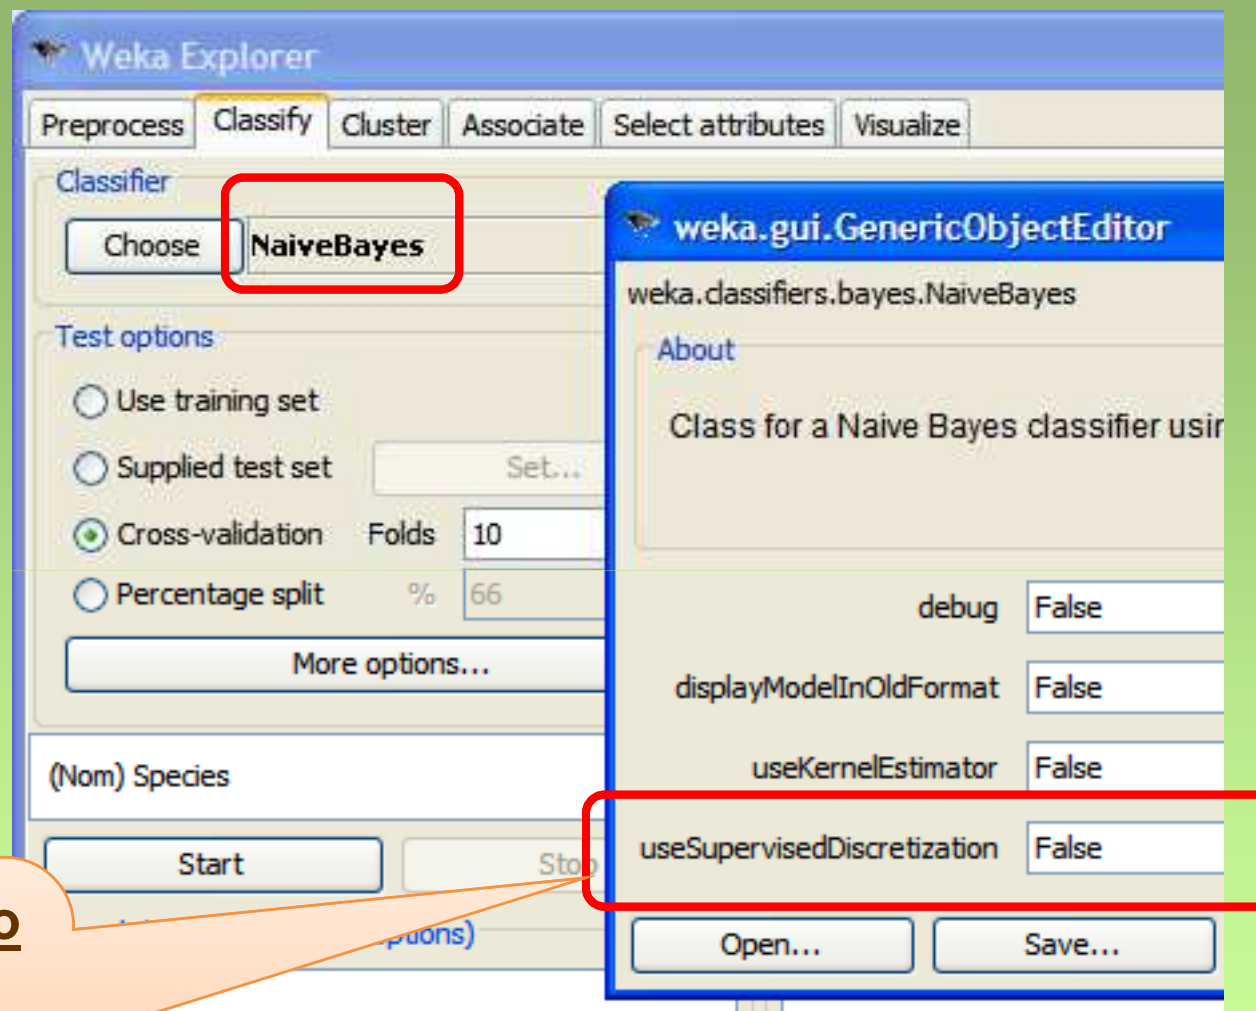
TRABAJO

César Hervás-Martínez
Grupo de Investigación AYRNA

**Departamento de Informática y Análisis
Numérico**
Universidad de Córdoba
Campus de Rabanales. Edificio Einstein.
Email: chervas@uco.es

2017-2018

85



Experimento

- 1 = False
- 2 = True
- 3 = False
- 4 = False

Weka Explorer

Preprocess Classify Cluster Associate Select attributes Visualize

Open file... Open URL... Open DB... Generate... Undo Edit... Save...

Filter

Choose **Discretize** -B 10 -M -1.0 -R first-last

Current relation

Relation: IqorsFirstDataset-weka.filters.unsupervised.attribute.Discretize

Instances: 150

Attributes

No	Name
1	<input checked="" type="checkbox"/> Sepal Length
2	<input checked="" type="checkbox"/> Sepal Width
3	<input checked="" type="checkbox"/> Petal Length
4	<input checked="" type="checkbox"/> Petal Width
5	<input checked="" type="checkbox"/> Species

weka.gui.GenericObjectEditor

weka.filters.unsupervised.attribute.Discretize

About

An instance filter that discretizes a range of numeric attributes in the dataset into nominal attributes.

More

Capabilities

attributeIndices first-last

bins 10

desiredWeightOfInstancesPerInterval -1.0

findNumBins False

ignoreClass False

invertSelection False

makeBinary False

useEqualFrequency False

Open... Save... OK Cancel

Visualize All

Experimento 3 = False 4 = True



Debe de ser un 8

Número total de casos
mal clasificados para
cada experimento

Experiment	1	2	3	4
Total	9	6	6	6
Instance	45	42	45	45
	72	45	72	72
	74	72	107	107
	100	107	116	116
	107	116	140	140
	116	140	148	148
	140			
	148			

Número de la instancia de
cada clase mal clasificada



MODELOS COMPUTACIONALES: CUARTO CURSO DEL GRADO DE ING. INFORMÁTICA EN COMPUTACION

Clasificación: Redes Bayesianas

César Hervás-Martínez
Grupo de Investigación AYRNA

**Departamento de Informática y Análisis
Numérico**
Universidad de Córdoba
Campus de Rabanales. Edificio Einstein.
Email: chervas@uco.es

2018-2019